

状态空间模型

陈堰平

chen@yanping.me

中国人民大学 统计学院

Nov.28,2007



模型形式

设 y_n 为 q 维时间序列。下面的模型被称为状态空间模型 (state space model)

$$\begin{matrix} x_t & = & F_t & x_{t-1} & + & v_t & & \text{(状态方程)} & (1) \\ (p \times 1) & & (p \times p) & (p \times 1) & & (p \times 1) & \end{matrix}$$

$$\begin{matrix} y_t & = & H_t & x_t & + & w_t & & \text{(观测方程)} & (2) \\ (q \times 1) & & (q \times p) & (p \times 1) & & (q \times 1) & \end{matrix}$$

- x_t 为不能直接观测的 p 维向量, 称为状态(state)。 v_t 称为系统噪声或状态噪声, w_t 称为观测噪声。 设 $v_t \stackrel{i.i.d}{\sim} N(0, Q_t)_p$, $w_t \stackrel{i.i.d}{\sim} N(0, R_t)_q$
- 用于时序分析的各种线性模型几乎都能用该状态空间模型表示, 从而用统一的算法进行处理。
- 假设初始状态 $x_0 \sim N(\mu_0, \Sigma_0)_p$



- ① 如果将(2)式看成时间序列 y_t 的回归模型的话, x_t 就可以看成回归系数。这时(1)式就可以看成是表达回归系数 x_t 随时间变化规律的模型。
- ② 把 x_t 看成要估计的信号, 则状态方程(1)式就成为表达信号 x_t 发生机制的模型, 而观测模型(2)式就表示在进行信号的观测时, 将信号进行某种变换时加进噪声的观测机制。



模型举例

局部水平模型 (local level model)

观测方程为:

$$X_t = \mu_t + n_t \quad (3)$$

不可观测的局部水平 μ_t 假设服从随机游走模型:

$$\mu_t = \mu_{t-1} + w_t \quad (4)$$

方程(4)是状态方程。假设 n_t 和 w_t 方差分别是 σ_n^2 和 σ_w^2 , σ_w^2/σ_n^2 被称为信噪比 (signal-to-noise ratio)。主要用来描述没有长期趋势或者季节性但是有短期相关性的数据。



模型举例

线性增长模型

$$\begin{aligned}X_t &= \mu_t + n_t \\ \mu_t &= \mu_{t-1} + \beta_{t-1} + w_{1,t} \\ \beta_t &= \beta_{t-1} + w_{2,t}\end{aligned}\tag{5}$$

改写成矩阵形式：

$$\begin{aligned}X_t &= (1, 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + n_t \\ \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \end{pmatrix} + \begin{pmatrix} w_{1,t} \\ w_{2,t} \end{pmatrix}\end{aligned}\tag{6}$$

- β_t 是趋势项，如果 β_t 为常数，则局部水平 μ_t 随时间变化线性增长
- X_t 的二阶差分平稳，自相关函数和MA(2)的相同



模型举例

基本结构模型

$$\begin{aligned}X_t &= \mu_t + i_t + n_t \\ \mu_t &= \mu_{t-1} + \beta_{t-1} + w_{1,t} \\ \beta_t &= \beta_{t-1} + w_{2,t} \\ i_t &= - \sum_{j=1}^{s-1} i_{t-j} + W_{3,t}\end{aligned}\tag{7}$$

μ_t 表示局部水平, β_t 表示局部趋势, i_t 表示局部季节指数, s 表示一年(或一季度)的期数

- 关于趋势与周期, 见Harvey(1985), Andrews(1994)



以 $s = 4$ 为例，即一年分四个季度的情况。设状态向量 $\theta_t = (\mu_t, \beta_t, i_t, i_{t-1}, i_{t-2})'$ 将基本结构模型方程改写成：

$$X_t = (1, 0, 1, 0, 0)\theta_t + n_t$$

$$\theta_t = \begin{pmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & -1 & -1 \\ 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \end{pmatrix} \theta_{t-1} + \begin{pmatrix} w_{1,t} \\ w_{2,t} \\ w_{3,t} \\ 0 \\ 0 \end{pmatrix} \quad (8)$$



模型举例

时变系数的回归模型

$$X_t = a_t + b_t u_t + n_t \quad (9)$$

设 $\theta_t = (a_t, b_t)'$, $h_t = (1, u_t)$, 则上式可以写成:

$$\begin{aligned} X_t &= h_t \theta_t + n_t \\ \theta_t &= \theta_{t-1} + w_t \end{aligned} \quad (10)$$



模型举例

时变系数的CAPM

$$\begin{aligned}r_t &= \alpha_t + \beta_t r_{M,t} + e_t, & e_t &\sim N(0, \sigma_e^2) \\ \alpha_{t+1} &= \alpha_t + \eta_t, & \eta_t &\sim N(0, \sigma_\eta^2) \\ \beta_{t+1} &= \beta_t + \epsilon_t, & \epsilon_t &\sim N(0, \sigma_\epsilon^2)\end{aligned}\tag{11}$$

这里 r_t 是某种资产的超出收益率（excess return）， $r_{M,t}$ 是市场组合的超出收益率。 $\{e_t, \eta_t, \epsilon_t\}$ 相互独立。



把模型改写成矩阵形式:

$$\begin{aligned} r_t &= (1, r_{M,t}) \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix} + e_t \\ \begin{pmatrix} \alpha_{t+1} \\ \beta_{t+1} \end{pmatrix} &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \alpha_t \\ \beta_t \end{pmatrix} + \begin{pmatrix} \eta_t \\ \epsilon_t \end{pmatrix} \end{aligned} \quad (12)$$



预测、滤波与平滑

状态空间模型的重要问题之一是用时间序列 y_t 的观测值来估计状态 x_t 。考虑用观测值 $Y_j = \{y_1, y_2, \dots, y_j\}$ 来求时刻 t 的状态 x_t 的估计值的问题

预测: $j < t$, 利用到目前为止的观测数据估计未来状态

滤波: $j = t$, 估计观测终点的状态, 即估计现在状态

平滑: $j > t$, 用到现在为止的观测值去估计过去状态



进行状态估计的Kalman滤波算法

要解决这些状态估计问题，只要求出在给定观测值 Y_j 时状态 x_t 的条件分布 $p(x_t|Y_j)$ 即可。(1)式和(2)式都是线性的， v_t 、 w_t 及 x_0 全都服从正态分布，所以 $p(x_t|Y_j)$ 也服从正态分布，因此状态估计问题实质上就是求条件分布的均值和协方差阵的问题。

设状态 x_t 的条件均值向量和协方差阵为：

$$\begin{aligned}x_{t|j} &\equiv E(x_t|Y_j) \\ V_{t|j} &\equiv E[(x_t - x_{t|j})(x_t - x_{t|j})']\end{aligned}\tag{13}$$

用Kalman滤波处理的是 $j = t - 1$ (1期预测)和 $j = t$ (滤波)这两种情况。反复交替计算1期预测和滤波，就能依次求出所需的各量。



进行状态估计的Kalman滤波算法

一步预测

$$\begin{aligned}x_{t|t-1} &= F_t x_{t-1|t-1} \\ V_{t|t-1} &= F_t V_{t-1|t-1} F_t' + Q_t\end{aligned}\tag{14}$$



进行状态估计的Kalman滤波算法

$$\begin{aligned}K_t &= V_{t|t-1} H_t' (H_t V_{t|t-1} H_t' + R_t)^{-1} \\x_{t|t} &= x_{t|t-1} + K_t (y_t - H_t x_{t|t-1}) \\&= K_t y_t + (I - K_t H_t) x_{t|t-1} \\V_{t|t} &= (I - K_t H_t) V_{t|t-1} \\&= V_{t|t-1} - K_t H_t V_{t|t-1}\end{aligned}\tag{15}$$



进行状态估计的Kalman滤波算法

平滑

滤波只用到时刻 t 为止的观测值来估计 x_t ，而平滑则是用所有观测值来进行状态的估计。因此，通过平滑一般来说可以得到比滤波精度更高的状态估计。

固定区间平滑：

$$\begin{aligned} A_t &= V_{t|t} F'_{t+1} V_{t+1|t}^{-1} \\ x_{t|N} &= x_{t|t} + A_t (x_{t+1|N} - x_{t+1|t}) \\ V_{t|N} &= V_{t|t} + A_t (V_{t+1|N} - V_{t+1|t}) A_t' \end{aligned} \quad (16)$$

其中 $t < N$.为了进行平滑，首先要用滤波计算

出 $\{x_{t|t-1}, x_{t|t}, V_{t|t-1}, V_{t|t}\}$ ($t = 1, 2, \dots, N$)，然后用(16)式所示的算法，从 $x_{N-1|N}$ ， $V_{N-1|N}$ 出发用后向前依次计算，直至求得 $x_{1|N}$ ， $V_{1|N}$



进行状态估计的Kalman滤波算法

长期预测


考虑用时序数据 $Y_t = \{y_1, y_2, \dots, y_t\}$ 来估计 h 期以后的状态 x_{t+h} , ($h > 1$) 这一长期预测的问题。

- 还未观测到 y_{t+1} , 则在形式上有 $Y_{t+1} = Y_t$ 。显然有 $x_{t+1|t+1} = x_{t+1|t}$, $V_{t+1|t}$ 成立, 这意味着为了第二步预测省略了对 y_{t+1} 的滤波, 只执行预测这一步就可以了。
- 一般地, 因 $Y_t = Y_{t+1} = \dots = Y_{t+h}$ 成立, 所以只要将1期预测的算法反复多次即可。

$$\begin{aligned}x_{t+i|t} &= F_{t+i}x_{t+i-1|t} \\V_{t+i|t} &= F_{t+i}V_{t+i-1|t}F_{t+i}' + Q_{t+i} \\(i &= 1, 2, \dots, h)\end{aligned}\tag{17}$$



用Kalman滤波和平滑算法进行递推计算的过程



\Rightarrow 表示预测, \Downarrow 表示滤波, \leftarrow 表示平滑, \rightarrow 表示长期预测



时间序列的预测

设在给定 Y_t 的条件下 y_{t+h} 的均值向量和协方差阵分别为 $y_{t+h|t} = E(y_{t+h}|Y_t)$ 和 $d_{t+h|t} = \text{Cov}(y_{t+h}|Y_t)$, 则

$$\begin{aligned} y_{t+h|t} &= E(H_{t+h}x_{t+h} + w_{t+h}|Y_t) \\ &= H_{t+h}x_{t+h|t} \end{aligned} \quad (18)$$

$$\begin{aligned} d_{t+h|t} &= \text{Cov}(H_{t+h}x_{t+h} + w_{t+h}|Y_t) \\ &= H_{t+h}\text{Cov}(x_{t+h}|Y_t)H'_{t+h} + H_{t+h}\text{Cov}(x_{t+h}, w_{t+h}|Y_t) \\ &\quad + \text{Cov}(w_{t+h}, x_{t+h}|Y_t)H'_{t+h} + \text{Cov}(w_{t+h}|Y_t) \\ &= H_{t+h}V_{t+h|t}H'_{t+h} + R_{t+h} \end{aligned} \quad (19)$$



时间序列欠测值的处理

- 在观测过程中，由于观测仪器的故障等偶然因素，或者由于观测对象和观测机制的物理性质的限制等原因，导致部分数据观测不到，这种实际上没有观测到的数据叫做欠测值（missing observation）。
- 如果只用连续观测的那部分数据，就会使数据的实际利用率变低。
- 用0或数据的均值来替代、或用直线插值法估计，会使分析结果产生较大偏差。
- 如果用时间序列的状态空间模型，对含有欠测值的数据也能精密地计算其似然函数。因此，在这种情况下也能求得参数的最大似然估计。



设 $I(t)$ 为到时刻 t 为止有观测值处的观测时刻的集合。显然，在没有欠测值时， $I(t) = \{1, 2, \dots, t\}$ 。设 $Y_t \equiv \{y_i | i \in I(t)\}$ ，则似然函数可以表达如下：

$$\begin{aligned} L(\theta) &= \log p(Y_N) \\ &= \sum_{n \in I(N)} \log p(y_n | Y_{n-1}, \theta) \end{aligned} \quad (20)$$

其中 $p(y_n | Y_{n-1}, \theta)$ 是给定观测值 Y_{n-1} 时 y_n 的分布。

提示

由条件概率公式 $P(A \cap B) = P(A|B)P(B)$

$$P(y_1, y_2, \dots, y_n | \theta) = P(y_n | y_1, y_2, \dots, y_{n-1}, \theta) P(y_1, y_2, \dots, y_{n-1} | \theta)$$



- 与长期预测类似，在 y_n 为欠测值时，因为有 $Y_n \equiv Y_{n-1}$ 成立，所以在Kalman滤波算法中，只要省略滤波值的计算即可
- 对所有的时刻 n 都实施预测计算，而只对满足 $n \in I(N)$ 的时刻 n 实施滤波计算
- 这样，在有欠测值的情况下也能依次求出状态的预测分布 $p(x_n|Y_{n-1})$

如果用(18)式和(19)式求得 $y_{n|n-1}$ 和 $d_{n|n-1}$ ，则时间序列的对数似然函数可以由下式给出

$$L(\theta) = -\frac{1}{2} \sum_{n \in I(N)} \left\{ q \log 2\pi + \log |d_{n|n-1}| \right. \\ \left. + (y_n - y_{n|n-1})' d_{n|n-1}^{-1} (y_n - y_{n|n-1}) \right\} \quad (21)$$



欠测值的插值步骤:

- 对有欠测值之处省略滤波计算, 同时用Kalman滤波求出预测值的分布 $\{x_{n|n-1}, V_{n|n-1}\}$ 和滤波值的分布 $\{x_{n|n}, V_{n|n}\}$
- 用平滑算法(16)即可求出对应欠测值的状态的平滑值 $x_{n|N}$
- 欠测值 y_n 的估计值由 $y_{n|N} = H_n x_{n|N}$ 给出, 估计误差的方差为 $d_{n|N} = H_n V_{n|N} H_n' + R_n$



- Newton-Raphson算法
- EM算法
 - 见shumway and Stoffer(1982)



模型扩展

含有输入的状态空间模型

外生变量（或固定的输入）会进入状态或观测中，假设输入向量为 u_t

$$\begin{matrix} x_t & = & F_t & x_{t-1} & + & \gamma_t & u_t & + & v_t \\ (p \times 1) & & (p \times p) & (p \times 1) & & (p \times r) & (r \times 1) & & (p \times 1) \end{matrix} \quad (\text{状态方程})$$

$$\begin{matrix} y_t & = & H_t & x_t & + & \Gamma_t & u_t & + & w_t \\ (q \times 1) & & (q \times p) & (p \times 1) & & (q \times r) & (r \times 1) & & (q \times 1) \end{matrix} \quad (\text{观测方程})$$



模型扩展

非高斯型状态空间模型

$$\begin{matrix} x_t & = & F_t & x_{t-1} & + & v_t & & \text{(状态方程)} \\ (p \times 1) & & (p \times p)(p \times 1) & & & (p \times 1) & & \end{matrix}$$

$$\begin{matrix} y_t & = & H_t & x_t & + & w_t & & \text{(观测方程)} \\ (q \times 1) & & (q \times p)(p \times 1) & & & (q \times 1) & & \end{matrix}$$

- 假设系统噪声 v_t 和观测噪声 w_t 服从密度函数为 $\varphi(v)$ 和 $\psi(w)$ 的白噪声。与前面的状态空间模型不同的是，系统噪声或观测噪声不一定服从正态分布。在这种情况下，一般来说状态向量 x_t 也是非高斯的，在这样的假设下，模型被称为非高斯型状态空间模型（non-Gaussian state space model）。
- 对于非高斯型状态空间模型，必需用Kalman滤波计算状态向量的分布。

$$p(x_t | x_{t-1}, Y_{t-1}) = p(x_t | x_{t-1}), \quad p(y_t | x_t, Y_{t-1}) = p(y_t | x_t)$$



一步预测:

$$\begin{aligned} p(x_t | Y_{t-1}) &= \int_{-\infty}^{\infty} p(x_t, x_{t-1} | Y_{t-1}) dx_{t-1} \\ &= \int_{-\infty}^{\infty} p(x_t | x_{t-1}, Y_{t-1}) p(x_{t-1} | Y_{t-1}) dx_{t-1} \\ &= \int_{-\infty}^{\infty} p(x_t | x_{t-1}) p(x_{t-1} | Y_{t-1}) dx_{t-1} \end{aligned} \quad (22)$$



滤波:

$$\begin{aligned} p(x_t|Y_t) &= p(x_t|y_t, Y_{t-1}) \\ &= \frac{p(y_t|x_t, Y_{t-1})p(x_t|Y_{t-1})}{p(y_t|Y_{t-1})} \\ &= \frac{p(y_t|x_t)p(x_t|Y_{t-1})}{p(y_t|Y_{t-1})} \end{aligned} \quad (23)$$

其中 $p(y_t|Y_{t-1})$ 可由 $\int_{-\infty}^{\infty} p(y_t|x_t)p(x_t|Y_{t-1}) dx_t$ 求得



设 $N > t$, 利用 $p(x_t|x_{t+1}, Y_N) = p(x_t|x_{t+1}, Y_n)$ 可得下式:

$$\begin{aligned} p(x_t, x_{t+1}|Y_N) &= p(x_{t+1}|Y_N)p(x_t|x_{t+1}, Y_N) \\ &= p(x_{t+1}|Y_N)p(x_t|x_{t+1}, Y_n) \\ &= p(x_{t+1}|Y_N) \frac{p(x_t|Y_t)p(x_{t+1}|x_t, Y_t)}{p(x_{t+1}|Y_t)} \\ &= p(x_{t+1}|Y_N) \frac{p(x_t|Y_t)p(x_{t+1}|x_t)}{p(x_{t+1}|Y_t)} \end{aligned} \quad (24)$$

由此, 得出平滑公式:

$$\begin{aligned} p(x_t|Y_N) &= \int_{-\infty}^{\infty} p(x_t, x_{t+1}|Y_N) dx_{t+1} \\ &= p(x_t|Y_t) \int_{-\infty}^{\infty} p(x_{t+1}|Y_N) \frac{p(x_{t+1}|Y_N)p(x_{t+1}|x_t)}{p(x_{t+1}|Y_t)} dx_{t+1} \end{aligned} \quad (25)$$



- 状态空间模型的Bootstrap方法
 - 见Stoffer and Wall(1991)
- 重要性抽样
 - Jungbacker and Koopman(2005)
- DLM with Switching
- Monte Carlo 方法与状态空间模型
 - 非线性模型
 - 非高斯型模型
 - 见Carlin, Polson and Stoffer(1992), Durbin and Koopman(1997)
- Stochastic Volatility 模型
-



Thank You!

